# GDN 物体记忆模块
# Exp-B：GenieSim 真实场景验证
# 实验方案

实验编号：Exp-B　状态：**PLANNED**

前置实验：Exp-A（COMPLETE，All PASS）

**研究问题：**

将 Exp-A 验证的 GDN 机制迁移到
GenieSim home_g2 真实家庭仿真场景，
使用真实 CLIP 视觉特征作为 key、GT 3D 位置作为 value，
**hit@1m 能否达到** $\geq 80\%$**?**

刘越　Tongji CS / PKU DLIB / 智元

2026 年 4 月

# 0 Contents


**1 背景与动机** **2**

**2 预注册假设** **2**
2.1 H1：CLIP Key 容量 . . . . . 2
2.2 H2：在线更新——物体移动恢复 . . . . . 3
2.3 H3：跨场景泛化（新增） . . . . . 3

**3 实验总体设计** **3**
3.1 环境配置 . . . . . 3
3.2 总体流程 . . . . . 4
3.3 评估指标定义 . . . . . 4

**4 子实验详细设计** **4**
4.1 B1：CLIP Key 容量 . . . . . 4
4.2 B2：在线更新 . . . . . 5
4.3 B3：跨场景泛化 . . . . . 5
4.4 B4（可选）：位置编码方案对比 . . . . . 5

**5 基线对比** **5**

**6 通过/失败判定表** **6**

**7 前置条件与执行计划** **6**
7.1 前置条件 . . . . . 6
7.2 执行时间线 . . . . . 6

**8 风险分析** **7**

**9 后续决策逻辑** **7**

**10 与 Exp-A 的对比** **8**

**11 输出产物** **8**

# 1 背景与动机

Exp-A 在合成数据上完整验证了 GDN 物体记忆模块（d=256, $\gamma$=0.999, $\eta$=0.5, momentum=False），三个预注册假设全部以大幅度通过（H1=100%, H2=100%, H3=0 pp 干扰）。然而，Exp-A 使用的是人工生成的随机正交单位向量作为物体 key，与真实部署时的情况存在以下关键差距：

**Exp-A 到 Exp-B 的四个关键差距**

1. **感知噪声**：真实 CLIP 特征在不同角度、光照、遮挡下对同一物体编码不完全一致，违反 Exp-A 的" 精确 key" 假设。
2. **语义纠缠**：外观相似物体（如两个马克杯）的 CLIP 特征余弦相似度较高，可能导致 key 冲突，而 Exp-A 的 key 是精确正交的。
3. **位置编码**：Exp-A 存储离散标签，Exp-B 需要存储连续 3D 坐标 $(x, y, z)$，检索时需要解码为物理位置。
4. **场景分布**：家庭场景物体类别、密度、布局与随机合成数据有本质差异，13 个场景变体提供了真实的分布多样性。

Exp-B 的核心目标是在受控仿真（GenieSim home_g2，GT 位置已知）条件下，回答" 真实感知下 GDN 还能用吗" 这一问题，为后续 Exp-C（GE-Act 集成）的 Go/No-Go 决策提供直接证据。

# 2 预注册假设

**Exp-B 假设总览**

**H1（CLIP 容量）**：CLIP ViT-L/14 特征作为 key，$d = 256$ GDN 在 $N \leq 50$ 常见家居物体时 hit@1m $\geq 80\%$。

**H2（在线更新）**：20% 物体移动后，3 次重观测使被移动物体恢复 hit@1m $\geq 75\%$；未移动物体下降 $\leq 5$ pp。

**H3（跨场景泛化）**：13 个 home_g2 变体中，$\geq 10/13$ 场景分别通过 H1、H2 条件。

**Overall Pass 条件：H1 $\wedge$ H2 $\wedge$ H3 同时通过。**

## 2.1 H1：CLIP Key 容量

**假设动机**

Exp-A Exp-5 表明：正交 key $\rightarrow$ 随机 key 的容量损失仅 6.3 pp（100% $\rightarrow$ 93.7%）。CLIP 特征的统计性质介于两者之间——同类物体特征相近（不利），跨类物体特征差异大（有利）。

理论估算：设 CLIP 特征的平均跨物体余弦相似度为 $\bar{c} \approx 0.05$（实测 Exp-A Exp-5 中随机向量的 $|\cos| = 0.0498$），则 GDN 容量公式 $\text{acc} \approx 1 - \bar{c}^2 \cdot (N-1)$ 预测 $N = 50$ 时准确率 $\approx 93.8\%$，高于 80% 阈值。

阈值设为 80%（而非 Exp-A 的 85%）以容纳真实感知噪声带来的额外性能损失。

**通过阈值**：hit@1m $\geq 80\%$（$N = 50$，13 个场景平均）

### 2.2 H2：在线更新——物体移动恢复

**假设动机**

Exp-A H2/H3 在精确正交 key 下实现了单次观测 100% 恢复、0 pp 干扰（代数保证）。引入真实感知噪声后，每次重观测的 key 向量与初始记录的 key 向量存在小角度偏差（估计余弦相似度 $\approx 0.85$–$0.95$），更新会引入轻微误差累积。

最坏情况估算：若每次重观测的 key 与初始 key 余弦相似度为 0.9，则 3 次更新后 value 的偏差量级约为 $1-(0.9)^3 = 27\%$，对应 hit@1m 损失估计 10–15 pp。故阈值从 Exp-A 的 $> 80\%$ 调整为 $\geq 75\%$。

未移动物体干扰：Exp-A 证明干扰 = 0 pp（精确正交时代数保证），真实场景因非正交性允许最多 5 pp 干扰。

**通过阈值**：被移动物体 3 次重观测后 hit@1m $\geq 75\%$；未移动物体 hit@1m 下降 $\leq 5$ pp

### 2.3 H3：跨场景泛化（新增）

**假设动机**

单场景通过不足以证明方案的鲁棒性。home_g2 的 13 个变体（8 个家庭 + 5 个厨房）在物体摆放位置、室内布局、光照条件上存在显著差异。若 GDN + CLIP 方案对某类场景配置系统性失败（如厨房场景中大量相似器皿），则需要在 Exp-C 之前先解决该问题。

允许 3 个场景失败（失败场景需做 case analysis 确认原因），目的是排查系统性问题而非偶发性噪声。

**通过阈值**：$\geq 10/13$ 场景分别通过 H1、H2 条件

## 3 实验总体设计

### 3.1 环境配置

Table 1: Exp-B 环境配置

| 配置项 | 值 |
|---|---|
| 仿真平台 | GenieSim 3.0 + Isaac Sim |
| 场景 | home_g2（8 个家庭变体 + 5 个厨房变体 = 13 个场景） |
| 机器人 | 智元 G2 |
| 巡视策略 | 脚本化固定 waypoints（不使用 RL） |
| 视觉编码器 | CLIP ViT-L/14（`openai/clip-vit-large-patch14`） |
| 图像分辨率 | $224 \times 224$（CLIP 标准输入） |
| 位置来源 | USD API 读取 GT 物体位置（精确到 mm） |
| GDN 配置 | $d = 256$, $\gamma = 0.999$, $\eta = 0.5$, momentum=False |
| 内存占用 | $256 \times 256 \times 4\,\mathrm{B} = 256\,\mathrm{KB}$（常量） |

### 3.2 总体流程

**实验流程（每个场景独立运行）**

1. **初始化**：重置场景，G2 站在起始点，$W \leftarrow 0$
2. **脚本化巡视**：G2 按固定 waypoints 遍历全室（4 个 waypoints，每处转 360° 扫描）
3. **记忆写入**：每当视野中出现新物体（可见度 $> 30\%$），执行：

$$k = \mathrm{CLIP}(I_t) \in \mathbb{R}^{768}, \quad v = (x, y, z)_{\mathrm{GT}} \in \mathbb{R}^3, \quad W \leftarrow \gamma W + \eta \cdot vk^\top$$

4. **检索评估（B1）**：巡视结束后，用各物体首次观测的 CLIP 特征 query $W$，计算 hit@1m
5. **物体移动（B2）**：随机移动 20% 的物体，G2 重新观测 $k = 1, 2, 3, 5$ 次，评估恢复曲线
6. **重复**：对 13 个场景各自独立重复步骤 1–5

### 3.3 评估指标定义

Table 2: 评估指标

| 指标 | 定义 | 意义 |
|---|---|---|
| hit@1m | query 位置与 GT 位置欧氏距离 $\leq 1.0\,\mathrm{m}$ 的比例 | 主要指标（实用性阈值） |
| hit@2m | query 位置与 GT 位置欧氏距离 $\leq 2.0\,\mathrm{m}$ 的比例 | 宽松指标 |
| hit@room | query 位置与 GT 在同一房间（房间 ID 相同） | 最宽松，失败时用于诊断 |
| 内存占用 | $W$ 矩阵大小（应始终为 256 KB） | 恒定内存验证 |
| 更新延迟 | 每次写入 $W$ 的耗时 | 实时性（目标 $< 1\,\mathrm{ms}$） |

## 4 子实验详细设计

### 4.1 B1：CLIP Key 容量

**目的**：在真实 CLIP 特征下验证 H1（容量假设）。

**实验设计**

**物体集合**：场景内所有可交互物体（预计 $N = 30$–$80$，按场景而异）

**Query 方式**：巡视结束后，对每个物体使用其**首次观测帧**的 CLIP 特征 query $W$：

$$\hat{v} = Wk/\|Wk\|, \quad \hat{\mathrm{pos}} = \mathrm{decode}(\hat{v})$$

**解码方式**（待定，见 B4）：直接取 $Wk$ 的 $\ell_2$-projection 作为位置向量。

**消融实验**：

- CLIP ViT-B/32 vs ViT-L/14（特征维度 512 vs 768，对容量的影响）
- $d = 256$ vs $d = 512$（GDN 维度对 CLIP 特征的适配性）

### 4.2 B2：在线更新

**目的**：在真实感知噪声下验证 H2（更新恢复假设）。

**实验设计**

**移动操作**：从场景物体中随机选取 20%，用 GenieSim API 移动到新位置（要求新位置与旧位置欧氏距离 $> 1.5\,\mathrm{m}$，否则 hit@1m 无法区分）。

**重观测**：G2 被引导至被移动物体附近（距物体 0.5–1.5 m），从随机角度拍摄 $k$ 帧图像（$k = 1, 2, 3, 5$），每帧执行一次 GDN 更新。

**评估**：更新后分别查询被移动物体和未移动物体，绘制 hit@1m 随 $k$ 的变化曲线。

**关键对比**：Exp-B B2 曲线 vs Exp-A H2 曲线（量化真实感知噪声的代价）。

### 4.3 B3：跨场景泛化

**目的**：验证 H3（13 个场景变体的泛化性）。

**实验设计**

在 13 个场景上各自独立运行 B1 + B2，汇总每个场景的 hit@1m（B1）和 3 次重观测后的恢复 hit@1m（B2）。

**统计分析**：

- 各场景 hit@1m 的均值 ± 标准差（方差过大说明稳定性不足）
- 对失败场景（hit@1m $< 80\%$）做 case analysis：失败物体类型、失败原因（遮挡/外观相似/光照）

### 4.4 B4（可选）：位置编码方案对比

**目的**：确定最优的 value 编码方式，为 Exp-C 提供技术决策依据。

Table 3: 位置编码方案对比

| 方案 | value 格式 | 解码方式 | 预期 hit@1m |
|---|---|---|---|
| A：连续 xyz | $[x, y, z]$ 归一化到 $[-1, 1]$ | 直接输出 $\ell_2$-proj | TBD |
| B：房间 + 方位 | 房间 ID (one-hot) + 8 方位 | 分类输出最近邻 | TBD |
| C：sin 位置编码 | $\mathrm{PE}(x, y, z) \to d_{\mathrm{pe}}$ 维向量 | 最近邻匹配候选库 | TBD |

## 5 基线对比

Table 4: 基线方法与预期性能

| 方法 | 描述 | 预期 hit@1m |
|---|---|---|
| **GDN（本方案）** | $d = 256$ GDN + CLIP ViT-L/14，256 KB 恒定内存 | TBD |
| Random retrieval | 随机返回场景内一个已观测位置 | $\approx 1/N$（$\leq 3\%$） |
| Last-seen | 返回 W 中最近一次更新该类物体的位置 | TBD |
| KV-Cache（无压缩） | 完整字典，逐帧追加，无容量限制 | 上界参考 |
| CLIP + L2-NN | 暴力最近邻检索全部历史帧 | 上界参考 |

**基线设计原则**

KV-Cache 和 CLIP+L2-NN 是无容量限制的上界基线，用于衡量 GDN 的压缩代价。若 GDN 与上界差距 $\leq 15\,\text{pp}$，则认为 256 KB 的压缩代价可接受。

# 6 通过/失败判定表

Table 5: Exp-B 预注册 Pass/Fail 判定（结果待填写）

| 假设 | 通过阈值 | 实测结果 | 判定 |
|---|---|---|---|
| H1（CLIP 容量） | hit@1m $\geq 80\%$，$N = 50$ | — | TBD |
| H2（更新恢复） | 3 次重观测后 hit@1m $\geq 75\%$ | — | TBD |
| H3（跨场景泛化） | $\geq 10/13$ 场景 H1+H2 通过 | — | TBD |
| **Overall** | H1 $\wedge$ H2 $\wedge$ H3 | — | TBD |

# 7 前置条件与执行计划

## 7.1 前置条件

Table 6: 前置条件清单

| 前置条件 | 状态 | 解锁方式 |
|---|---|---|
| GenieSim 3.0 + Isaac Sim 运行 | TODO | 安装到 gpu-server，确认 home_g2 可渲染 |
| 全部 13 个场景变体可用 | TODO | GenieSim 场景包下载/解压 |
| USD API 读取 GT 物体位置 | TODO | 参考 GenieSim 文档 USD stage API |
| CLIP ViT-L/14 推理可调用 | TODO | `pip install open_clip_torch` |
| G2 脚本化巡视路径定义 | TODO | 4 个 waypoints 手工标定，存为 JSON |

## 7.2 执行时间线

Table 7: Exp-B 执行计划（从 Exp-A 完成后起）

| 时间 | 任务 | 交付物 |
|---|---|---|
| Day 1–2 | 环境搭建 | GenieSim + home_g2 能渲染，G2 能移动 |
| Day 3 | 数据管道 | CLIP 推理 + USD API 位置读取 + GDN 写入 |
| Day 4 | 巡视路径 | 4 个 waypoints 定义，单场景 B1 跑通 |
| Day 5–6 | B1 全量运行 | 13 个场景 hit@1m，容量曲线 |
| Day 7 | B2 运行 | 移动 + 恢复曲线，13 个场景 |
| Day 8 | B3+B4 | 跨场景汇总，位置编码方案对比（可选） |
| Day 9 | 报告生成 | exp_b_report.pdf，更新 DeepScientist |
| Day 10 | Go/No-Go 决策 | 若 All Pass $\rightarrow$ 准备 Exp-C 方案 |

## 8 风险分析

Table 8: Exp-B 风险矩阵

| 风险 | 概率 | 影响 | 缓解方案 |
|---|---|---|---|
| CLIP 跨视角不一致（同物体不同角度特征差异大） | 中 | H1 失败 | 多视角聚合：记录时取 $K$ 次观测特征均值后写入 $W$ |
| 外观相似物体 key 冲突（两个马克杯） | 中 | H1 局部失败 | 加入位置先验辅助：key $= \alpha\,\mathrm{CLIP}(I) + (1-\alpha)\,\mathrm{PE}(\mathrm{pos})$ |
| GenieSim 无法在现有 GPU 运行 | 低 | 整体阻塞 | 降级到 Habitat-Sim（HM3D 数据集）+ 预渲染图像 |
| 物体被完全遮挡，CLIP 特征不可靠 | 低 | 漏记录 | 只写入可见度 $> 30\%$ 的观测帧 |
| hit@1m 系统性未达标（H1 Fail） | 低 | 暂停 Exp-C | 分析失败物体类型，针对性改进 key 设计或增大 $d$ |

## 9 后续决策逻辑

**Exp-B All Pass → Exp-C**

**条件**：H1 ∧ H2 ∧ H3 同时通过。

**行动**：进入 Exp-C——将 GDN Memory Tokens 注入 GE-Act 的 Action DiT 上下文，评估标准任务不退化（$\leq 5$ pp）+ 记忆任务有提升（hit@1m 提升 $\geq 20$ pp vs 无记忆基线）。

**依赖**：需要智元提供 GE-Act 代码访问权限（Action DiT 部分）。

**Exp-B 部分通过 → 针对性改进后重跑**

**情形**：H1 Pass，H3 部分失败（失败场景 $\leq 5$）。

**行动**：对失败场景进行 case analysis，针对性改进（多视角聚合、位置辅助 key），在失败场景上重跑 B1。不需要重跑全部 13 个场景。

**Exp-B H1 Fail → 重新审视 key 设计**

**情形**：hit@1m $< 70\%$（远低于阈值，不是边界失败）。

**行动**：重新审视 key 设计——CLIP 是否足够？是否需要 fine-tune CLIP？是否需要混合 key（CLIP 特征 + 物体类别 embedding）？

**决策点**：H1 Fail 不代表 GDN 本身有问题（Exp-A 已验证 GDN 机制），意味着 CLIP 作为 key encoder 的适配性存在问题，是 key 设计问题，不是 memory 设计问题。

## 10 与 Exp-A 的对比

Table 9: Exp-A（合成）与 Exp-B（GenieSim）对比

| 维度 | Exp-A（合成） | Exp-B（GenieSim） |
|---|---|---|
| Key 来源 | 随机正交单位向量 | CLIP ViT-L/14 真实视觉特征 |
| Value 来源 | 合成位置标签（离散） | USD API GT 位置（连续 xyz） |
| 场景 | 无场景（纯向量运算） | home_g2（13 个变体） |
| 物体数 $N$ | 20–300（系统扫描） | 场景实际物体（约 30–80） |
| 通过阈值 | hit@1m $\geq$ 85% | hit@1m $\geq$ 80%（放宽 5 pp） |
| 硬件需求 | CPU only，88.6 s | GPU（Isaac Sim 渲染），TBD |
| 状态 | **COMPLETE，All PASS** | **PLANNED** |

## 11 输出产物

Table 10: Exp-B 预期输出产物

| 产物 | 路径 | 状态 |
|---|---|---|
| 结果 JSON | `results/exp_b_results.json` | 待生成 |
| 图 1：容量曲线 | `results/b1_clip_capacity.png` | 待生成 |
| 图 2：更新恢复曲线 | `results/b2_update_curve.png` | 待生成 |
| 图 3：跨场景汇总 | `results/b3_scene_breakdown.png` | 待生成 |
| PDF 报告 | `results/exp_b_report.pdf` | 待生成 |
| DeepScientist 记录 | `quests/001/experiments/exp_b_genesim.md` | 已写（本方案） |

方案版本：v1.0　状态：PLANNED　日期：2026 年 4 月 12 日