GDN 物体记忆模块
Exp-C：GE-Act 复现 & 集成
及消融实验方案

实验编号：Exp-C　状态：**PLANNED**
前置实验：Exp-A（合成验证，PASS）→ Exp-B（GenieSim，PASS）

核心问题：

将 Exp-A/B 验证的 GDN 物体记忆模块（256 KB 恒定）
注入 GE-Act 的 Action DiT 第三路 cross-attention，
在不降低标准任务性能（≤ 5 pp）的前提下，
能否提升轨迹精度 nDTW $\geq +15$ pp?

执行平台	A100（/mnt/oss）+ GPU Server（8× RTX 5090）
评测基准	CALVIN, LIBERO, ICRA26 WM Competition
GE-Act 架构	LTX-Video Action DiT, 28 层, action_in_channels=14
GDN 配置	$d = 256$, $\gamma = 0.999$, $\eta = 0.5$, momentum=False

刘越　Tongji CS / PKU DLIB / 智元　2026 年 4 月

0 Contents

1 背景与动机 **2**
- 1.1 从 Exp-A/B 到 Exp-C 的逻辑链 . . . 2
- 1.2 为什么 GDN 能解决 nDTW 问题 . . . 2
- 1.3 架构分析：注入点已存在 . . . 2

2 预注册假设 **3**
- 2.1 H_C1：GE-Act 复现基线 . . . 3
- 2.2 H_C2：GDN 注入不破坏标准任务 . . . 3
- 2.3 H_C3：GDN 注入改善 nDTW . . . 3
- 2.4 H_C4：内存效率 . . . 4

3 GE-Act 复现方案（C1 子实验） **4**
- 3.1 复现目标与环境 . . . 4
- 3.2 复现步骤 . . . 4
- 3.3 已知风险 . . . 5

4 GDN Memory 集成方案（C2/C3 子实验） **5**
- 4.1 系统架构 . . . 5
- 4.2 技术细节 . . . 5
  - 4.2.1 Memory Token 生成 . . . 5
  - 4.2.2 训练策略 . . . 6
- 4.3 GDN 更新时机 . . . 6

5 消融实验设计（C3 子实验） **6**
- 5.1 消融 A：记忆容量（GDN 维度 d） . . . 6
- 5.2 消融 B：注入层数 . . . 7
- 5.3 消融 C：遗忘率 γ . . . 7
- 5.4 消融 D：Memory Token 数量 M . . . 7

6 ICRA26 竞赛方案（C4 子实验） **7**
- 6.1 竞赛背景 . . . 8
- 6.2 GDN 在竞赛场景中的作用 . . . 8
- 6.3 Finetune + 提交策略 . . . 8

7 预期结果 **8**
- 7.1 H_C1 预期：GE-Act 复现 . . . 8
- 7.2 H_C2 预期：GDN 注入不破坏标准任务 . . . 9
- 7.3 H_C3 预期：nDTW 提升 . . . 9
- 7.4 H_C4 预期：消融实验结论 . . . 9

8 Pass/Fail 判定表 **10**

9 执行计划 **10**

10 与 Exp-A/B 的完整链路 **10**

11 输出产物 **11**

1 背景与动机

1.1 从 Exp-A/B 到 Exp-C 的逻辑链

已验证的事实（Exp-A + Exp-B）

- **GDN 机制可行**（Exp-A All Pass）：$d = 256$ 矩阵以 256 KB 恒定内存存储 ≥ 256 个物体-位置关联，100% 检索准确率，零灾难遗忘，单次观测即可恢复移动物体。
- **真实 CLIP 特征兼容**（Exp-B Pass）：CLIP ViT-L/14 特征作为 key，GenieSim home_g2 场景 hit@1m $\geq 80\%$，跨 13 个场景泛化稳定。
- **关键结论**：GDN 能以 256 KB 的代价为机器人维护一份" 物体在哪里" 的实时记忆，且与感知框架无关。

Exp-C 的问题是：**这份记忆能让动作更好吗？**

GE-Act（Genie-Envisioner 的 Action Model）是当前 state-of-the-art 的操作策略，在 CALVIN 上达到平均 4.260 子任务、LIBERO 平均 96.5%。但在 ICRA26 世界模型赛道的竞赛数据上，GE-Sim 零样本 nDTW 仅 0.388（EVAC 基线 0.907），根本原因是 **action conditioning 不工作**——模型不知道目标物体在哪里，无法规划正确轨迹。

1.2 为什么 GDN 能解决 nDTW 问题

nDTW（normalized Dynamic Time Warping）衡量预测轨迹与参考轨迹的对齐程度。轨迹偏差的主要来源有两类：

Table 1: nDTW 低的两类原因与 GDN 的作用

问题来源	具体表现	GDN 的作用
物体位置不知道	机器人直走到错误位置，轨迹方向完全偏	提供物体 $(x, y, z) \rightarrow$ 正确终点
多步任务记忆丢失	第二步操作时忘了第一步放的东西	恒定记忆不随步数增加而遗忘

集成思路：GDN 维护物体位置记忆 W，在 Action DiT 的每个 `ActionTransformerBlock` 里通过第三路 cross-attention（`attn3_hidden_states`）注入 memory tokens。动作生成时，每个 attention block 都能" 看到" 场景中有哪些物体、在什么位置，从而生成朝向正确目标的轨迹。

1.3 架构分析：注入点已存在

阅读 `models/action_patches/patches.py`，`ActionTransformerBlock.forward()` 已经有第三路 cross-attention 参数：

```
def forward(
    self,
    hidden_states,            # action tokens
    encoder_hidden_states,    # attn2: visual/language context
    temb,                     # diffusion timestep
    rotary_emb=None,
    encoder_attention_mask=None,
    attn3_hidden_states=None,    # <-- 第三路: GDN memory tokens 注入点
) -> torch.Tensor:
```

`attn3_hidden_states` 目前未被使用（默认 `None`）。GDN 集成只需要：

1. 用 GDN W 生成 M 个 memory tokens（线性投影 $W \in \mathbb{R}^{d \times d} \rightarrow \mathbb{R}^{M \times d_{\text{model}}}$）

2. 将 memory tokens 传入每个 ActionTransformerBlock 的 `attn3_hidden_states`
3. **无需修改 backbone 权重**，只训练 GDN 投影层（参数量极小）

2 预注册假设

Exp-C 假设总览（4 个）

H_C1（复现基线）：GE-Act 在 CALVIN 上复现 Avg.Subtasks ≥ 4.0（论文 4.260）。
H_C2（无伤害）：GDN 注入后 CALVIN Avg.Subtasks 下降 ≤ 5 pp（不破坏原有能力）。
H_C3（轨迹提升）：GDN 注入后 ICRA26 nDTW 提升 $\geq +15$ pp（从当前 0.388 到 ≥ 0.538）。
H_C4（内存效率）：GDN（256 KB）在 nDTW 上达到 KV-Cache 上界的 $\geq 90\%$。
Overall Pass 条件：H_C1 $\wedge$ H_C2 $\wedge$ H_C3 同时通过。

2.1 H_C1：GE-Act 复现基线

假设动机

这是 Exp-C 的前提条件验证。GE-Act 论文报告 CALVIN Avg.Subtasks = 4.260。目前已有官方权重（`pretrained_weights/ge_act/ge_act_calvin.safetensors`）和官方评测代码（`experiments/eval_calvin.py`）。

允许 ≤ 5 pp 的复现误差，来源：浮点精度差异、不同版本依赖库的数值差异。若复现结果 < 4.0（偏差 $> 6\%$），说明环境配置有问题，需要先排查再进行集成实验。

通过阈值：CALVIN Avg.Subtasks ≥ 4.0；LIBERO 平均成功率 $\geq 93\%$

2.2 H_C2：GDN 注入不破坏标准任务

假设动机

在不修改 backbone 权重、仅增加 GDN 投影层的情况下，memory tokens 通过 `attn3` cross-attention 注入。理论上：若 GDN 记忆内容与当前任务相关，attn3 会产生正向贡献；若 GDN 记忆与当前任务无关（空记忆或 off-topic 物体），attn3 应产生接近零的激活（注意力 softmax 会分散到 encoder_hidden_states）。

标准任务（CALVIN/LIBERO）已经有充分的 visual context（attn2），GDN 记忆是补充信息而非替代信息，因此理论上不应引起明显性能下降。5 pp 阈值对应随机初始化投影层引入的最大合理噪声。

通过阈值：CALVIN Avg.Subtasks 下降 ≤ 5 pp（相较 H_C1 基线）

2.3 H_C3：GDN 注入改善 nDTW

假设动机

ICRA26 竞赛数据的低 nDTW（0.388）主要来源于 action conditioning 不工作：GE-Sim 是视频预测模型，其动作条件通过 `traj_maps`（轨迹热图）传入，但零样本推理时这些热图质量不稳定。

GDN memory tokens 提供物体的绝对 3D 位置，可以替代或辅助 `traj_maps` 作为轨迹

终点的空间约束。预期提升机制：(1) memory token 直接编码" 目标物体在 (x, y, z)"，action DiT 知道往哪儿走；(2) 多步任务中物体记忆不丢失，中间步骤的动作更连贯。

目标从 0.388 → 0.538（+15 pp）是保守估计，来自 Exp-B hit@1m $\geq$ 80% 的位置精度换算。理想情况下可能达到 EVAC 基线 0.907 附近。

通过阈值：ICRA26 nDTW $\geq$ 0.538（+15 pp），总分 Score $\geq$ 0.70

2.4 H_C4：内存效率

假设动机

这是 GDN 相对于 KV-Cache 的核心价值主张：用 256 KB 固定内存实现接近无限 KV-Cache 的性能。若 GDN 只能达到 KV-Cache 的 $< 90\%$，说明 256 维的压缩损失了太多信息，需要考虑更大的 d。Exp-A 在合成数据上显示 GDN (d=256) vs KV-Cache 的差距仅 ~ 6 pp，真实场景中预计差距 ≤ 10 pp。

通过阈值：GDN nDTW $\geq 0.9\times$ KV-Cache nDTW（上界基线）

3 GE-Act 复现方案（C1 子实验）

3.1 复现目标与环境

Table 2: GE-Act 复现配置

配置项	值
模型权重	`pretrained_weights/ge_act/ge_act_calvin.safetensors`（2112M 参数）
推理代码	`experiments/eval_calvin.py` + `eval_libero.py`
CALVIN 权重	`configs/ltx_model/calvin/action_model_calvin.yaml`
LIBERO 权重	`configs/ltx_model/libero/action_model_libero.yaml`
执行平台	A100（推理），GPU Server（备用）
动作维度	14 维（左右臂各 xyz + rpy + gripper）
CALVIN 目标	Avg.Subtasks $\geq$ 4.0（论文 4.260）
LIBERO 目标	平均成功率 $\geq$ 93%（论文 96.5%）

3.2 复现步骤

CALVIN 复现流程

1. 确认 A100 上 conda env `genie_envisioner` 已安装
2. 运行：`bash experiments/eval_calvin.sh`（修改 ckpt 路径）
3. 评测指标：Len-1 到 Len-5 成功率 + Avg.Subtasks
4. 预期耗时：~2–4 小时（CALVIN 需要 1000 次 rollout）

3.3 已知风险

GE-Act 复现风险

Action 复现失败：GE-Act 的 Action DiT 有 28 层，权重文件 2.1 GB，若 yaml 配置不匹配会导致静默错误（维度不匹配时 PyTorch 会 broadcast 而不是报错）。

缓解：对比 A100 和 GPU Server 上的 yaml 配置，确保 `action_in_channels=14`, `inner_dim=2048`, `num_layers=28` 一致。运行前先做单步推理验证输出形状。

4 GDN Memory 集成方案（C2/C3 子实验）

4.1 系统架构

GDN-GE-Act 系统架构

感知层		
RGB 图像 I_t	$\longrightarrow$	CLIP ViT-L/14 $\rightarrow$ key $k \in \mathbb{R}^{768}$
GT/估计位置 (x, y, z)	$\longrightarrow$	value $v \in \mathbb{R}^3$
记忆层（GDN，256 KB）		
$W \leftarrow \gamma W + \eta \cdot (v - Wk)k^\top$		
$W \in \mathbb{R}^{256\times256}$，推理时 $\hat{v} = Wq$		
投影层（可训练，参数量极小）		
$\mathrm{MemTokens} = \mathrm{Linear}(\mathrm{vec}(W))_{M\times d_{\mathrm{model}}}$，$M = 16$, $d_{\mathrm{model}} = 2048$		
Action DiT 层（28 层，权重冻结）		
`attn1`: 动作自注意力	`attn2`: 视觉语言	`attn3`: GDN memory tokens

4.2 技术细节

4.2.1 Memory Token 生成

GDN 矩阵 $W \in \mathbb{R}^{256\times256}$ 共 65536 个元素，通过线性投影生成 M 个 memory tokens：

$$\mathrm{MemTokens} = W_{\mathrm{proj}} \cdot \mathrm{reshape}(W, [256^2]) \in \mathbb{R}^{M\times d_{\mathrm{model}}}$$

其中 $W_{\mathrm{proj}} \in \mathbb{R}^{M\cdot d_{\mathrm{model}}\times256^2}$ 是唯一新增的可训练参数（$M = 16$, $d_{\mathrm{model}} = 2048$：参数量 $= 16 \times 2048 \times 65536 = 2.1\,\mathrm{B}$，过大）。

Memory Token 维度问题与解决方案

直接投影 $\mathrm{vec}(W)$ 维度过大（65536）。改用**分解投影**：

$$W \in \mathbb{R}^{d\times d} \xrightarrow{\text{行采样或 SVD}} U \in \mathbb{R}^{M\times d} \xrightarrow{\mathrm{Linear}} \mathbb{R}^{M\times d_{\mathrm{model}}}$$

方案 A（行采样）：取 W 的前 $M = 16$ 行，$\mathrm{Linear}(256 \rightarrow 2048)$，参数量 $= 16 \times 256 \times 2048/16 = 32768$（极小）。
方案 B(查询式):用预设的 M 个可学习查询向量 $Q \in \mathbb{R}^{M\times256}$ query GDN：$\mathrm{MemTokens} = QW^\top \in \mathbb{R}^{M\times256} \xrightarrow{\mathrm{Linear}} \mathbb{R}^{M\times2048}$，参数量 $= M \times 256 + 256 \times 2048 \approx 524\,\mathrm{K}$。
推荐方案 B：查询式更接近 attention 的语义，可学习查询向量代表" 什么物体信息对动作最有用"。

4.2.2 训练策略

Table 3: GDN-GE-Act 训练配置

配置项	值
冻结参数	GE-Act backbone 全部权重（28 层 ActionTransformerBlock）
可训练参数	GDN 查询向量 Q（$M \times 256$）+ 投影层（256×2048）
可训练参数量	$\approx 524\,\mathrm{K}$（相比 GE-Act 总参数 2.1 B，比例 0.025%）
训练数据	CALVIN 训练集（已有）或 ICRA26 竞赛训练集
学习率	10^{-4}（仅更新投影层，backbone 用 0）
步数	10000 步（参考 GE-Act LIBERO 50000 步，投影层参数少 $\times 5$）
Batch size	128（与 LIBERO 训练一致）
平台	A100 单卡（2.1 B frozen + 0.5 M trainable，约 20 GB 显存）

4.3 GDN 更新时机

在线更新策略

GDN 在推理阶段持续更新（非训练阶段），更新时机：

1. **每帧更新**：每次 CLIP 编码新帧后立即执行 $W \leftarrow \gamma W + \eta \cdot e \cdot k^\top$
2. **置信度门控**：仅当 CLIP 特征与已存储 key 的最大余弦相似度 < 0.95 时写入（避免重复写入同一物体的轻微变化帧）
3. **动作执行时不更新**：动作生成的 forward pass 期间 GDN W 保持不变（避免递归依赖）

5 消融实验设计（C3 子实验）

消融实验的目的是回答三个问题：

1. **记忆容量**：$d = 256$ 是否是最优的？更大的 d 有多少收益？
2. **注入深度**：memory tokens 注入所有 28 层 vs 只注入最后几层？
3. **记忆类型**：GDN vs KV-Cache vs No Memory——性能和内存的 Pareto 前沿在哪里？

5.1 消融 A：记忆容量（GDN 维度 d）

Table 4: 消融 A：GDN 维度对性能的影响

配置	d	内存（KB）	CALVIN Avg	nDTW
No Memory	—	0	(H_C1 基线)	(基线)
GDN-64	64	16	TBD	TBD
GDN-256（本方案）	256	256	TBD	TBD
GDN-512	512	1024	TBD	TBD
GDN-1024	1024	4096	TBD	TBD
KV-Cache	∞	$O(N)$	TBD（上界）	TBD（上界）

预期结论：性能随 d 增大先快后平（Exp-A 已显示 $d = 256$ 在合成数据上饱和），256 KB 是 Pareto 最优点。

5.2 消融 B：注入层数

Table 5: 消融 B：memory token 注入层数对性能的影响

配置	注入层	CALVIN Avg	nDTW
All-28	全部 28 层	TBD	TBD
Last-14（推荐）	后 14 层	TBD	TBD
Last-7	后 7 层	TBD	TBD
First-7	前 7 层	TBD	TBD
None	不注入	（H_C1 基线）	（基线）

假设：动作 DiT 的前几层负责特征提取，后几层负责动作合成。记忆信息在后半段注入更有效（类似 BERT 的 layer-wise probing 结论）。

5.3 消融 C：遗忘率 γ

Table 6: 消融 C：遗忘率 γ 对 nDTW 的影响（物体移动频率高时）

γ	语义	预期 nDTW
1.000	永不遗忘	高（静态场景），低（物体移动后）
0.999	慢速遗忘（Exp-A 推荐）	最优（平衡静态和动态）
0.990	快速遗忘	低（记忆更新过快，不稳定）
0.900	极快遗忘	退化到 last-seen

5.4 消融 D：Memory Token 数量 M

Table 7: 消融 D：memory token 数量 M 对计算开销与性能的影响

M	额外参数量	推理 FLOPs 增加	预期 nDTW
4	~131 K	$< 1\%$	TBD
16（推荐）	~524 K	$\sim 3\%$	TBD
64	~2.1 M	$\sim 10\%$	TBD
256	~8.4 M	$\sim 35\%$	TBD

6 ICRA26 竞赛方案（C4 子实验）

6.1 竞赛背景

Table 8: ICRA26 World Model Track 竞赛数据

指标	EVAC 基线	GE-Sim 零样本（当前）
PSNR	20.98 (0.599)	18.69 (0.534)
Scene Consistency	0.901	0.932
nDTW	0.907	0.388
Total Score	**0.736**	**0.618**

差距主要在 nDTW（−0.519）。Scene Consistency 已经超过 EVAC（+0.031）。**核心任务：修复 nDTW。**

6.2 GDN 在竞赛场景中的作用

竞赛数据来自 AgiBotWorld（真实机器人操作），GDN 记忆在每个 episode 开始时清空，随着 episode 内的帧积累物体位置信息。每个 episode 的物体布局固定（无重排），GDN 可以逐渐完善物体位置记忆，到 episode 后段动作质量应显著提升。

6.3 Finetune + 提交策略

竞赛 finetune 计划

1. **Stage 1**（2 天）：仅在竞赛训练集上 finetune GDN 投影层（10000 步，A100 单卡），不修改 GE-Act backbone
2. **Stage 2**（1 天）：视 Stage 1 结果，若 nDTW < 0.6，解冻最后 4 层 ActionTransformerBlock 联合微调（LoRA，rank=16）
3. **Inference**：在竞赛 test set 上运行 `scripts/infer_competition.py`，生成提交包
4. **提交**：上传 HuggingFace leaderboard `agibot-world/ICRA26WM`

目标分数：≥ 0.750（超过 EVAC 基线），理想目标 ≥ 0.850。

7 预期结果

7.1 H_C1 预期：GE-Act 复现

Table 9: H_C1 预期复现结果

评测集	论文数字	预期复现	Pass 阈值
CALVIN Len-1	0.950	0.940 ± 0.01	≥ 0.90
CALVIN Len-3	0.857	0.840 ± 0.02	≥ 0.80
CALVIN Avg	4.260	4.1 ± 0.1	≥ 4.0
LIBERO Average	96.5%	$94 \pm 2\%$	$\geq 93\%$

依据：官方权重 + 官方评测代码，环境配置正确时应完全复现。

7.2 H_C2 预期：GDN 注入不破坏标准任务

Table 10: H_C2 预期结果（GDN 注入前后对比）

配置	CALVIN Avg	变化	LIBERO Avg	变化
GE-Act（基线）	4.1	—	94%	—
GE-Act + GDN（空记忆，M=16）	4.0 ± 0.1	≤ -0.1	$93\% \pm 1\%$	≤ -1 pp
GE-Act + GDN（有记忆，M=16）	4.1 ± 0.1	≈ 0	$94\% \pm 1\%$	≈ 0

依据：GDN 注入通过 attn3（第三路 cross-attention）进行，与 attn1（自注意力）和 attn2（视觉语言 cross-attention）独立。空记忆时 attn3 输出接近零，不影响原有动作生成。有记忆时提供额外物体位置信息，在物体位置明确的任务（CALVIN/LIBERO）中信息冗余但不有害。

7.3 H_C3 预期：nDTW 提升

Table 11: H_C3 预期结果（ICRA26 竞赛指标）

配置	nDTW	PSNR	SceneConsist	Score
GE-Sim 零样本（当前）	0.388	18.69	0.932	0.618
EVAC 基线	0.907	20.98	0.901	0.736
GDN-GE-Act Stage 1（预期）	0.60 ± 0.05	19.5 ± 0.5	0.93	$\mathbf{0.72 \pm 0.03}$
GDN-GE-Act Stage 2（预期）	0.75 ± 0.05	20.5 ± 0.5	0.93	$\mathbf{0.80 \pm 0.03}$

依据：

- nDTW 从 $0.388 \to 0.60$：GDN 提供物体位置后，action DiT 能生成朝向正确目标的粗略轨迹（80% hit@1m × 50% nDTW 改善估算）
- nDTW 从 $0.60 \to 0.75$：Stage 2 解冻最后 4 层后，动作精细化对准竞赛数据分布
- Score 估算：$\frac{0.75-0.388}{0.907-0.388} \times (0.907 - 0.388) + 0.618 \approx 0.80$

7.4 H_C4 预期：消融实验结论

消融预期结论

消融 A（维度）：nDTW 随 d 增大先快后平，$d = 256$ 达到 KV-Cache 上界的 $\geq 90\%$。$d = 512$ 在 $d = 256$ 基础上提升 < 2 pp。

消融 B（注入层）：Last-14 最优，全部 28 层与 Last-14 差距 < 1 pp 但计算开销更大（不推荐）。前 7 层注入无效（特征提取层不受益于位置记忆）。

消融 C（遗忘率）：$\gamma = 0.999$ 最优，与 Exp-A 结论一致。$\gamma = 1.0$ 在静态场景无差别，但物体移动后退化；$\gamma = 0.99$ 记忆更新过快，nDTW 不稳定。

消融 D（Token 数）：$M = 16$ 是 Pareto 最优（性能 $\approx M = 64$，计算开销仅 3%）。

8 Pass/Fail 判定表

Table 12: Exp-C 预注册 Pass/Fail 判定（结果待填写）

假设	通过阈值	实测结果	判定
H_C1（复现基线）	CALVIN Avg ≥ 4.0	—	TBD
H_C2（无伤害）	下降 ≤ 5 pp	—	TBD
H_C3（nDTW 提升）	nDTW ≥ 0.538 (+15 pp)	—	TBD
H_C4（内存效率）	GDN $\geq 90\%$ KV-Cache	—	TBD
Overall	H_C1 $\wedge$ H_C2 $\wedge$ H_C3	—	TBD

9 执行计划

Table 13: Exp-C 执行时间线

时间	任务	平台
Day 1	GE-Act 复现（CALVIN eval）	A100
Day 2	GE-Act 复现（LIBERO eval）+ 记录 H_C1	A100
Day 3	实现 GDN 投影层 + attn3 注入代码（≈ 100 行）	本地
Day 4	空记忆测试（验证 H_C2 不降性能）	A100
Day 5–6	竞赛数据 finetune Stage 1（10000 步）	A100
Day 7	竞赛 test set 推理，提交第一版	A100
Day 8–9	消融实验（A/B/C/D，并行运行）	A100 + GPU Server
Day 10	Stage 2 finetune（若 Stage 1 分数 < 0.72）	A100
Day 11	最终提交 + 报告生成	—

10 与 Exp-A/B 的完整链路

Table 14: 三阶段实验链路对比

维度	Exp-A（合成）	Exp-B（GenieSim）	Exp-C（GE-Act）
验证对象	GDN 机制本身	GDN + CLIP 特征	GDN + Action Policy
Key 来源	随机正交向量	CLIP ViT-L/14	CLIP ViT-L/14
Value 来源	合成标签	USD API GT 位置	竞赛数据 GT 轨迹
评测指标	检索准确率	hit@1m	nDTW, PSNR, Score
通过阈值	acc $\geq 85\%$	hit@1m $\geq 80\%$	nDTW ≥ 0.538
状态	PASS	PASS	PLANNED

11 输出产物

Table 15: Exp-C 预期输出产物

产物	路径	状态
GE-Act 复现结果 JSON	`results/exp_c_geact_repro.json`	待生成
GDN 集成代码	`models/gdn_memory_module.py`	待实现
消融结果 JSON	`results/exp_c_ablation.json`	待生成
消融图：维度-性能曲线	`results/c_ablation_dim.png`	待生成
消融图：注入层-性能曲线	`results/c_ablation_layers.png`	待生成
竞赛提交包	`outputs/icra26_submission.zip`	待生成
PDF 报告	`experiments/exp_c_report.pdf`	待生成
DeepScientist 记录	`quests/001/experiments/ exp_c.md`	本文件

方案版本：v1.0　状态：PLANNED　日期：2026 年 4 月 12 日